ESTADÍSTICA MULTIDIMENSIONAL · SEMANAS 1 A 6

# Análisis Exploratorio Integral

## Comportamiento Crediticio y Riesgo Financiero — Dataset Sintético


Oscar Manuel Contreras Gacha

20221020052

Juan Pablo Sarmiento Ramírez

20221020138

Steven Navarro Parrales

20221020048

Juan Diego Grajales Castillo

20221020128


De la importación de los datos a la selección final de variables

# Ficha técnica y autores ‖ Quiénes hicimos el análisis y sobre qué datos

## Autores

| | |
|---|---|
| Oscar Manuel Contreras Gacha | 20221020052 |
| Juan Pablo Sarmiento Ramírez | 20221020138 |
| Steven Navarro Parrales | 20221020048 |
| Juan Diego Grajales Castillo | 20221020128 |

## Fuente y enlace

Kaggle — *Credit Card Customer Behavior Analysis & Prediction*

`https://www.kaggle.com/code/devraai/credit-card-customer-behavior-analysis-prediction/input`

## Naturaleza de los datos

Dataset **sintético** sobre comportamiento crediticio, capacidad financiera y riesgo de 50.000 clientes simulados de tarjeta de crédito.

## Contexto económico

Análisis desarrollado en el contexto económico de la **India**: todos los valores monetarios están en rupias indias (**INR**).

**50.000**
clientes simulados (filas)

**30**
variables medidas (columnas)

**11**
módulos de análisis

# Descripción logística de los datos ‖ Inspección, lectura y calidad de la matriz

## Cómo llegan los datos a R

Se inspeccionan las primeras líneas en crudo (`readLines`) antes de cargar el archivo: separador de columnas coma (`,`), decimal punto (`.`), encabezado descriptivo en la primera fila.

```
credit <- read.csv(file = ruta,
  header = TRUE, sep = ",",
  dec = ".",
  stringsAsFactors = FALSE)
```

## Dimensiones de la matriz $\mathbf{X} \in \mathbb{R}^{n \times p}$

| $n = 50.000$ | $p = 30$ |
|---|---|
| observaciones (clientes) | variables medidas |

## Auditoría de calidad (Módulo 2)

- **0%** de celdas vacías — matriz 100% completa
- **0** filas o identificadores duplicados
- Sin valores centinela ni niveles mal escritos

**Lectura:** la matriz llega limpia y completa — ninguna estrategia frente a faltantes (casos completos, por pares, imputación) es necesaria en este dataset.

# Cómo lee R los datos ‖ Clasificación por escala de medición, no por tipo de almacenamiento

`str(credit)` reporta **4** columnas de texto y **26** numéricas — pero el criterio real es si la media o una distancia métrica constante tienen sentido sobre la variable, no cómo la almacena R.

## Nominal (sin orden)

- `Customer_ID`: 50.000 únicos (id puro)
- `Gender`: 2 niveles
- `Occupation`: 6 niveles laborales

## Ordinal (con orden)

- `Card_Type`: 5 niveles Basic $<$ Silver $<$ Gold $<$ Platinum $<$ Signature
- Jerarquía real de tarjeta

## Cuantitativas (26)

- Monetarias: ingreso, cupo, gastos, saldos (15)
- Ratios: `Payment_Ratio`, `Credit_Utilization`
- Conteos: edad, EMI, transacciones (9)

**Casos corregidos:** `Card_Type` es texto pero tiene orden real $\rightarrow$ **ordinal**, no nominal. Variables de rango corto (`Age`, `EMI_Count`) siguen siendo **cuantitativas**: su media es interpretable pese al rango acotado.

# Diccionario de variables (1/3) ‖ 9 de 26 variables numéricas — perfil y consumo general

| Variable | Qué mide (lenguaje de negocio) |
|---|---|
| `Age` | Edad del titular, en años. |
| `Annual_Income` | Ingreso anual declarado por el cliente (INR). |
| `Credit_Limit` | Cupo total aprobado en la tarjeta (INR). |
| `Card_Age_Months` | Antigüedad de la tarjeta, en meses. |
| `Monthly_Spending` | Gasto mensual total: suma de las 7 categorías de consumo. |
| `Monthly_Transactions` | Número de compras realizadas en el mes. |
| `Avg_Transaction_Value` | Ticket promedio (gasto mensual / número de transacciones). |
| `Online_Shopping_Spending` | Gasto mensual en compras por internet. |
| `Grocery_Spending` | Gasto mensual en supermercado. |

**Variables derivadas de otras (no independientes):** `Monthly_Spending` es la **suma exacta** de las 7 categorías de gasto (`Online_Shopping` a `Utility_Bill`, en las siguientes 2 diapositivas); `Avg_Transaction_Value` = `Monthly_Spending` / `Monthly_Transactions` es el ticket promedio — un **cociente**, no una medición directa.

# Diccionario de variables (2/3) ‖ 9 de 26 variables numéricas — categorías de gasto y saldos

| Variable | Qué mide (lenguaje de negocio) |
|---|---|
| `Fuel_Spending` | Gasto mensual en combustible. |
| `Dining_Spending` | Gasto mensual en restaurantes. |
| `Travel_Spending` | Gasto mensual en viajes. |
| `Entertainment_Spending` | Gasto mensual en entretenimiento. |
| `Utility_Bill_Spending` | Gasto mensual en servicios públicos pagados con la tarjeta. |
| `Outstanding_Balance` | Saldo que el cliente aún debe. |
| `Statement_Balance` | Saldo facturado en el último corte del extracto. |
| `Payment_Amount` | Monto que el cliente pagó en el mes. |
| `Payment_Ratio` | Proporción del saldo facturado que el cliente efectivamente pagó. |

**Otra relación derivada:** `Outstanding_Balance` y `Statement_Balance` miden prácticamente la misma magnitud de deuda en dos momentos del ciclo de facturación ($r = 0.997$) — casi la misma información contada dos veces.

# Diccionario de variables (3/3) ‖ 8 de 26 variables — comportamiento, uso y riesgo

| Variable | Qué mide (lenguaje de negocio) |
|---|---|
| `Credit_Utilization` | Proporción del cupo que el cliente tiene usada. |
| `Cash_Advance_Amount` | Monto retirado como avance en efectivo. |
| `EMI_Count` | Número de compras diferidas a cuotas vigentes. |
| `International_Transactions` | Número de compras hechas en el exterior. |
| `Reward_Points_Earned` | Puntos de recompensa acumulados, según el gasto. |
| `Reward_Points_Redeemed` | Puntos de recompensa que el cliente ya redimió. |
| `Mobile_App_Login` | Número de ingresos a la app móvil en el mes. |
| `Credit_Score` | Puntaje crediticio asignado al cliente — **variable de riesgo**. |

**Más cocientes derivados:** `Payment_Ratio` ≈ `Payment_Amount` / `Statement_Balance`; `Credit_Utilization` ≈ `Outstanding_Balance` / `Credit_Limit`; `Reward_Points_Earned` se calcula como función del gasto mensual. `Credit_Score` es la variable de riesgo: el resto del análisis termina relacionándose con ella.

# Diccionario de variables (4/4): categóricas ‖ Las 4 variables de texto, completas

| Variable | Naturaleza | Qué mide y sus categorías |
|---|---|---|
| `Customer_ID` | Nominal (id.) | Identificador único del cliente — 50.000 valores distintos, uno por fila. No mide nada; se excluye de todo cálculo numérico. |
| `Gender` | Nominal (2) | Género del titular: **F**, **M** — sin jerarquía entre ellos. |
| `Occupation` | Nominal (6) | Ocupación laboral: **Retired**, **Student**, **Business Owner**, **Government Employee**, **Private Employee**, **Self-Employed**. |
| `Card_Type` | Ordinal (5) | Categoría de tarjeta, con jerarquía real: **Basic** $<$ **Silver** $<$ **Gold** $<$ **Platinum** $<$ **Signature**. |

**Con esto, el diccionario queda completo:** 26 variables cuantitativas (3 diapositivas anteriores) + estas 4 cualitativas = las **30 variables** de la matriz **X**. Sus distribuciones gráficas se muestran más adelante, en la sección de categóricas.

# Qué significa cada transformación ‖ Tres herramientas de R, tres efectos distintos

### `log(x+1)` — comprime colas largas

Aplica logaritmo natural (sumándole 1 antes, para que los ceros no rompan el cálculo). Una variable con cola derecha extrema queda mucho más simétrica: comprime las distancias entre valores grandes mucho más que entre valores pequeños.

`Cash_Advance_Amount` (skew 6.78) → tras `log(x+1)`, mucho más manejable.

### `scale()` — estandariza (Z-score)

Resta la media y divide por la sd: $z = (x - \bar{x})/s$. Resultado con media 0 y sd 1, sin importar la unidad. **No cambia la forma**, solo la escala — se aplica *después* de `log()` en sesgadas, directo en simétricas.

### `factor()` — declara una categórica

Le dice a R que una columna no es un número para promediar, sino **niveles/etiquetas** discretos. Paso obligatorio antes de graficar o modelar una nominal (`Gender`, `Occupation`).

`factor(x, ordered=TRUE)` agrega un **orden** explícito — necesario para `Card_Type`, que sí tiene jerarquía real.

**Por qué log → scale, y no al revés:** estandarizar primero una variable sesgada solo reescala la asimetría, no la corrige. Comprimir la cola con `log()` antes sí cambia la forma hacia algo simétrico.

# Transformación de variables (1/2) ‖ Regla reproducible, no a mano

**16**
log(x+1) + scale()
(|skew| > 1)

**5**
scale()
(simétricas)

**5**
Excluir
(redundantes/derivadas)

| Variable | Skew | Transformación | Variable | Skew | Transformación |
|---|---|---|---|---|---|
| Age | 0.69 | scale() | Utility_Bill_Spending | 4.35 | log+scale |
| Annual_Income | 2.55 | log+scale | Outstanding_Balance | 4.02 | Excluir |
| Credit_Limit | 3.01 | log+scale | Statement_Balance | 3.80 | log+scale |
| Card_Age_Months | 1.14 | log+scale | Payment_Amount | 4.20 | log+scale |
| Monthly_Spending | 3.00 | Excluir | Payment_Ratio | -1.04 | Excluir |
| Monthly_Transactions | 0.54 | scale() | Credit_Utilization | 0.53 | Excluir |
| Avg_Transaction_Value | 3.90 | log+scale | Cash_Advance_Amount | 6.78 | log+scale |
| Online_Shopping_Spending | 4.56 | log+scale | EMI_Count | 0.17 | scale() |
| Grocery_Spending | 4.01 | log+scale | International_Transactions | 2.11 | log+scale |
| Fuel_Spending | 4.69 | log+scale | Reward_Points_Earned | 3.50 | Excluir |
| Dining_Spending | 4.64 | log+scale | Reward_Points_Redeemed | 6.55 | log+scale |
| Travel_Spending | 5.71 | log+scale | Mobile_App_Login | 0.33 | scale() |
| Entertainment_Spending | 5.01 | log+scale | Credit_Score | -0.58 | scale() |

# Transformación de variables (2/2) ‖ Las categóricas necesitan otro tratamiento

**Las 4 variables cualitativas: ni log() ni scale() tienen sentido sobre texto**

| Variable | Naturaleza real | Transformación |
|---|---|---|
| `Customer_ID` | Identificador nominal único | Quitar (no es variable de análisis) |
| `Gender` | Nominal (2 niveles) | factor() |
| `Occupation` | Nominal (6 niveles) | factor(), o codificación dummy |
| `Card_Type` | Ordinal (5 niveles) | factor(ordered=TRUE) o entero 1–5 |

**Criterio aplicado (reproducible, no a mano)**

Se marca **excluir** si la variable ya es redundante o derivada; si no, `log(x+1)` antes de estandarizar cuando la asimetría supera 1 en valor absoluto, y `scale()` sola en caso contrario.

**16 de 26** numéricas usan `log()` antes de estandarizar: gasto, saldo y conteos con masa en cero.

**5 se excluyen**: no por mala calidad, sino por volver casi singular la matriz de covarianzas.

**Estadísticos descriptivos de `Credit_Score`**

Variable de referencia del módulo: el resto del informe termina relacionándose con ella.

| Media | Mediana | Desv.Std |
|---|---|---|
| 636.4 | 640 | 87.3 |

La media queda **por debajo** de la mediana: primera señal numérica de una cola hacia la izquierda, antes de graficar nada.

**Regla de Sturges:** $k = 1 + \log_2(n)$

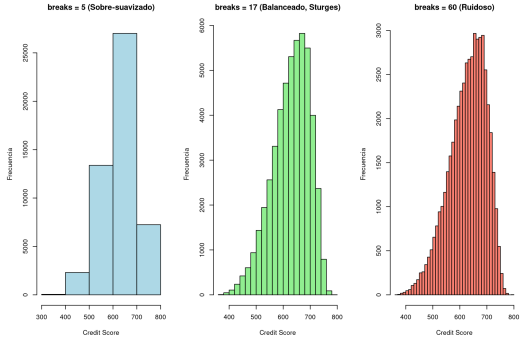
$$k = 1 + 3.322 \cdot \log_{10}(n)$$

n = **50.000** observaciones

k = **17** intervalos sugeridos

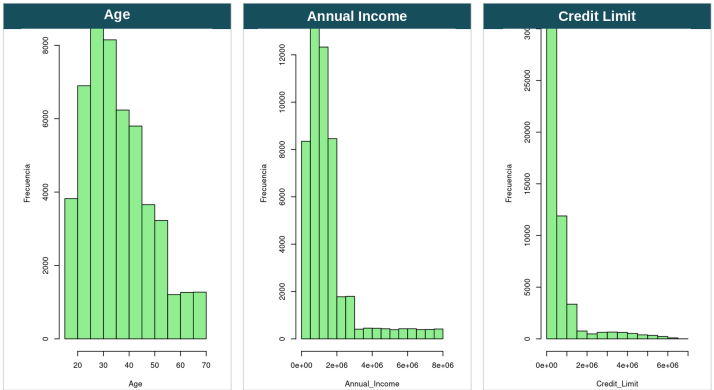
**Por qué importa:** el número de cortes (`breaks`) de un histograma no es estético, cambia lo que el gráfico *dice* sobre los mismos datos. $k$ no depende de la variable — es la misma fórmula para las 26 numéricas, porque solo usa $n$, común a todas.

# El efecto del número de cortes ‖ Sobre-suavizado, balanceado, ruidoso




Con `breaks=5` la asimetría hacia la izquierda desaparece; con `breaks=60` aparecen dientes y huecos de ruido de muestreo. Con $k = 17$ (Sturges) se ve la forma real: unimodal, centrada cerca de 640, con cola izquierda.

# Histogramas de las 26 variables (1/9) ‖ Grupo 1/9 — edad, ingreso y cupo

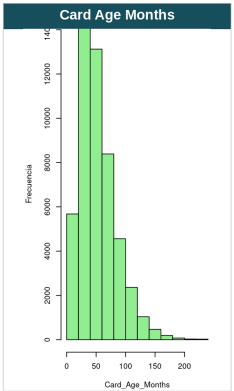


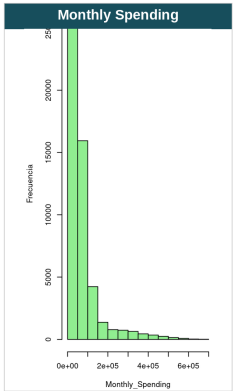

**Age** (skew 0.69): casi simétrica, leve sesgo derecho; se concentra entre 27 y 44 años.

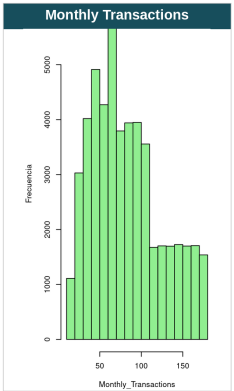
**Annual_Income** (skew 2.55): cola derecha típica de ingresos — mayoría cerca de la mediana, pocos ganan mucho más.

**Credit_Limit** (skew 3.01): hereda la cola de `Annual_Income`; solo toma valores redondeados.

# Histogramas de las 26 variables (2/9) ‖ Grupo 2/9 — antigüedad y actividad mensual




**Card_Age_Months** (skew 1.14): más tarjetas nuevas que antiguas; masa acumulada en los primeros años.

**Monthly_Spending** (skew 3.00): suma de 7 categorías ya sesgadas — acumula todas sus colas.

**Monthly_Transactions** (skew 0.54): conteo acotado (15 a 179/mes), casi simétrica.

# Histogramas de las 26 variables (3/9) ‖ Grupo 3/9 — ticket y primeras categorías

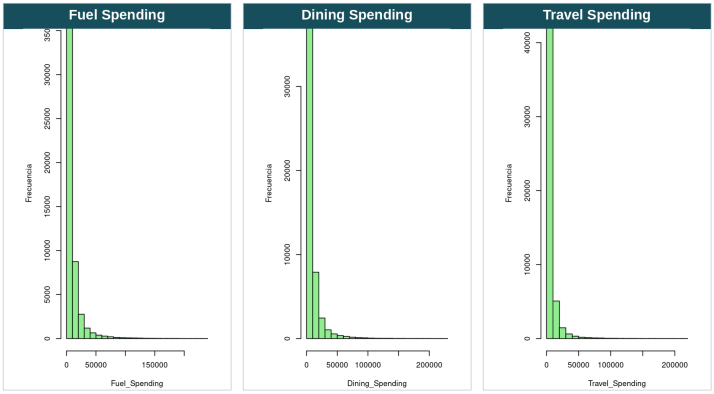



**Avg_Transaction_Value** (skew 3.90): cociente gasto/transacciones — dominan tickets pequeños.

**Online_Shopping_Spending** (skew 4.56): pico pegado al origen, mayoría gasta poco.

**Grocery_Spending** (skew 4.01): mediana más alta del grupo — gasto recurrente casi universal.

# Histogramas de las 26 variables (4/9) ‖ Grupo 4/9 — gasto discrecional

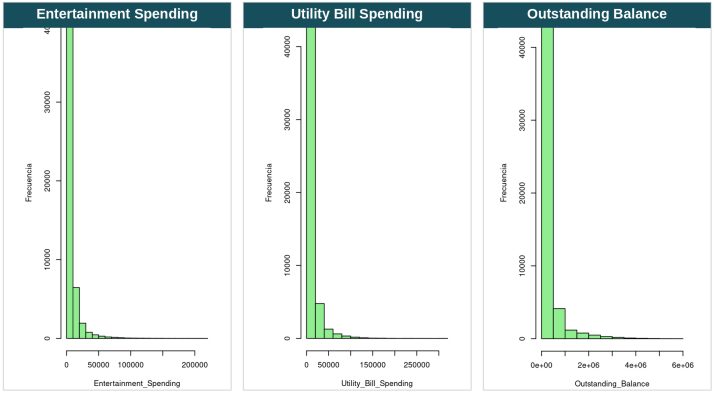



**Fuel_Spending** (skew 4.69): depende de tener vehículo; gasto bajo mayoritario.

**Dining_Spending** (skew 4.64): gasto discrecional — mayoría moderada, minoría con montos altos.

**Travel_Spending** (skew 5.71): el gasto más esporádico — la cola más larga del grupo.

# Histogramas de las 26 variables (5/9) ‖ Grupo 5/9 — entretenimiento y saldos

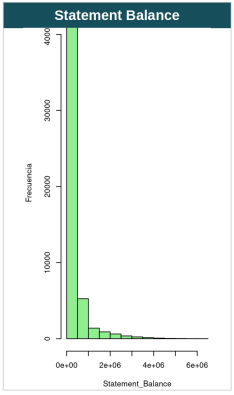


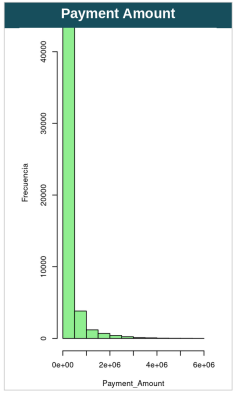

**Entertainment_Spending** (skew 5.01): discrecional y ocasional, cola de consumo intensivo.

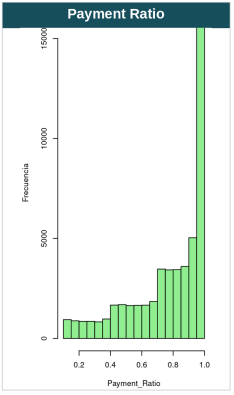
**Utility_Bill_Spending** (skew 4.35): monto acotado y frecuente; cola de facturas altas.

**Outstanding_Balance** (skew 4.02): sigue la lógica del gasto y el cupo.

# Histogramas de las 26 variables (6/9) ‖ Grupo 6/9 — saldo, pago y ratio



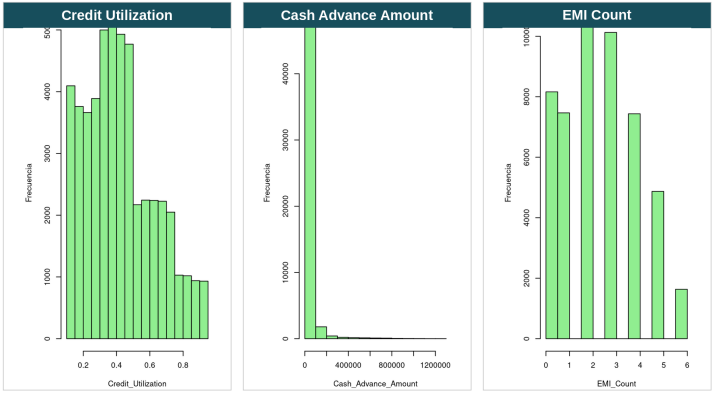




**Statement_Balance** (skew 3.80): casi idéntica a `Outstanding_Balance`.

**Payment_Amount** (skew 4.20): proporcional a lo facturado; reproduce la forma del saldo.

**Payment_Ratio** (skew -1.04): única cola a la izquierda — acotada en 1, mayoría paga casi todo.

# Histogramas de las 26 variables (7/9) ‖ Grupo 7/9 — utilización, avances y cuotas

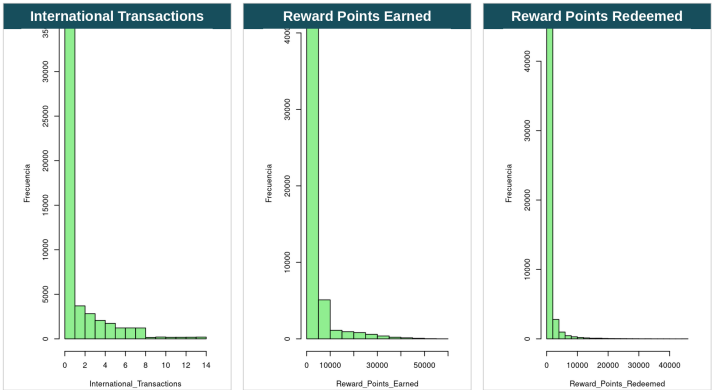



**Credit_Utilization** (skew 0.53): proporción acotada [0,1] — compacta, sin colas.

**Cash_Advance_Amount** (skew 6.78): inflada en cero — más de la mitad nunca hace avances.

**EMI_Count** (skew 0.17): solo 7 valores enteros (0 a 6) — barras separadas.

# Histogramas de las 26 variables (8/9) ‖ Grupo 8/9 — internacional y recompensas

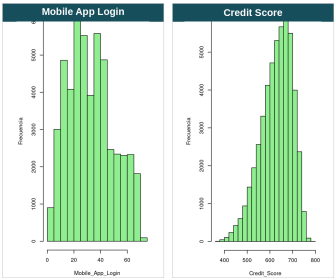



**International_Transactions** (skew 2.11): típicamente cero — cola discreta.

**Reward_Points_Earned** (skew 3.50): función del gasto — reescala `Monthly_Spending`.

**Reward_Points_Redeemed** (skew 6.55): acumulación en cero — muchos no redimen.

# Histogramas de las 26 variables (9/9) ‖ Grupo 9/9 — app y puntaje

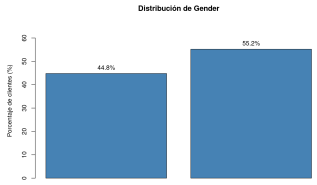


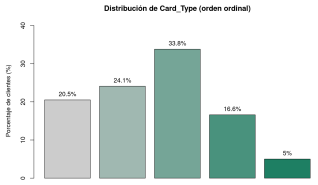

**Mobile_App_Login** (skew 0.33): conteo acotado (2 a 71 sesiones) — hábito uniforme.

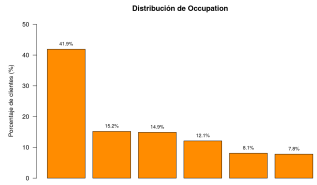
**Credit_Score** (skew -0.58): acotado por diseño — cola corta de alto riesgo.

**Síntesis de las 26:** domina la cola derecha con pico en el origen. Excepciones: `Payment_Ratio` (cola izquierda) y las proporciones/conteos cortos (`Credit_Utilization`, `EMI_Count`, `Mobile_App_Login`), compactas y simétricas.

# Distribución de categóricas ‖ Frecuencia relativa; Card_Type en orden ordinal




**55.2% M**

vs. 44.8% F — diferencia mínima

**Gold 33.8%**

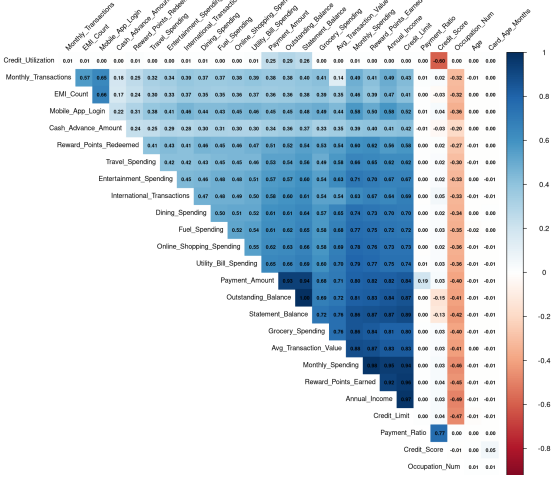
nivel más común; Signature el más raro (5%)

**Private 41.9%**

ocupación dominante, casi 3x la siguiente

Las tres llegan limpias: `Gender` (2), `Card_Type` (5) y `Occupation` (6) niveles, sin niveles "fantasma" ni `NA`.

# Mapa de calor de correlaciones ‖ 325 pares posibles, reordenados por similitud (hclust)



# Síntesis de la matriz de correlación ‖ Qué bloques y qué separaciones deja ver el mapa

## Colinealidad casi perfecta (r > 0.95)

- `Outstanding_Balance` – `Statement_Balance`: **0.997**
- `Monthly_Spending` – `Reward_Points_Earned`: **0.980**
- `Credit_Limit` – `Annual_Income`: **0.974**

## Ingresos, cupo y gasto: un solo bloque

`Annual_Income`, `Credit_Limit` (0.974) y `Monthly_Spending` (0.945) se mueven juntas: a mayor ingreso, más cupo y más gasto.

## Determinantes del riesgo (`Credit_Score`)

- `Payment_Ratio`: $r =$ **0.767**
- `Credit_Utilization`: $r =$ **-0.599**
- `Annual_Income`: apenas $r =$ **0.032**

**Variables "aisladas":** `Payment_Ratio` y `Credit_Utilization` correlacionan casi 0 con las variables de volumen de dinero — el comportamiento de pago es independiente de cuánto gana o gasta el cliente.

# Criterios de selección: $|r|$ y $\eta^2$ ‖ Dos medidas de asociación, para dos tipos de par distintos

## $|r|$: correlación de Pearson

**numérica $\sim$ numérica**

$$r = \frac{\text{cov}(X, Y)}{s_X \, s_Y}$$

Mide qué tan fuerte es la relación **lineal** entre dos variables numéricas. Va de $-1$ a $1$: cercano a los extremos indica relación fuerte (directa o inversa); cercano a 0, poca relación lineal. Se usa $|r|$ para ordenar pares por fuerza, sin importar el signo.

## $\eta^2$: eta al cuadrado

**numérica $\sim$ categórica**

$$\eta^2 = \frac{SC_{\text{entre grupos}}}{SC_{\text{total}}}$$

No existe $r$ de Pearson entre un número y una etiqueta. $\eta^2$ (de un ANOVA de un factor) mide qué **proporción de la varianza** de la numérica explica el grupo. Va de 0 a 1 — el mismo tipo de medida que $r^2$, para cuando un lado no es numérico.

**Por qué hace falta un criterio objetivo:** con $p = 26$ hay $\binom{26}{2} = 325$ pares posibles — mirarlos uno por uno no es factible. $|r|$ y $\eta^2$ los ordenan y dejan ver, con evidencia, cuáles merecen un análisis bivariado profundo.

# Selección objetiva de variables (1/2) ‖ $|r|$ de Pearson entre las 26 numéricas

**Top pares por $|r|$ (de 325 posibles)**

| v1 | v2 | r |
|---|---|---|
| Outstanding_Balance | Statement_Balance | 0.997 |
| Monthly_Spending | Reward_Points_Earned | 0.980 |
| Annual_Income | Credit_Limit | 0.974 |
| Credit_Limit | Reward_Points_Earned | 0.958 |

**Par numérico más fuerte que NO es redundancia contable:** `Annual_Income`–`Credit_Limit` ($r = 0.974$). Los pares por encima en la tabla son casi la misma cantidad de dinero contada dos veces.

**Lo que de verdad explica el riesgo:** `Payment_Ratio` ($r = 0.767$) y `Credit_Utilization` ($r = -0.599$) son, por enorme margen, las correlaciones más fuertes con `Credit_Score` — no las variables de dinero ($r \approx 0.03$).

# Selección objetiva de variables (2/2) ‖ $\eta^2$: varianza explicada por la categórica

## Criterio 2: $\eta^2$ numérica $\sim$ categórica

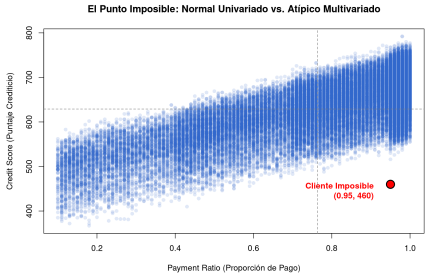
| Comparación | $\eta^2$ |
|---|---|
| Credit_Limit $\sim$ Card_Type | 0.7997 |
| Annual_Income $\sim$ Card_Type | 0.6837 |
| Annual_Income $\sim$ Occupation | 0.6367 |
| Credit_Score $\sim$ Card_Type | 0.0023 |
| Annual_Income $\sim$ Gender | 0.0001 |

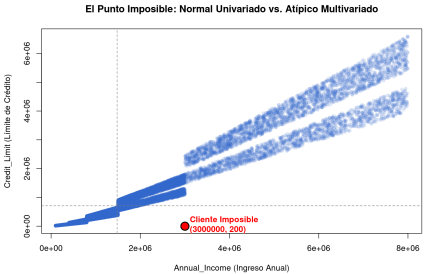
## Selección final: 4 pares reciben análisis bivariado profundo

| Par | Criterio | Valor | Por qué |
|---|---|---|---|
| Income–Limit | $\lvert r \rvert$ | 0.974 | más fuerte, no redundante |
| Payment_Ratio–Score | $\lvert r \rvert$ | 0.767 | predictor #1 del riesgo |
| Utilization–Score | $\lvert r \rvert$ | -0.599 | predictor #2 del riesgo |
| Income–Occupation | $\eta^2$ | 0.637 | más fuerte num.-categ. |

**Coherencia interna:** `Card_Type` y `Occupation` explican bien las variables de dinero, pero casi nada de `Credit_Score` — el riesgo no depende de cuánto gana el cliente, sino de cómo paga.

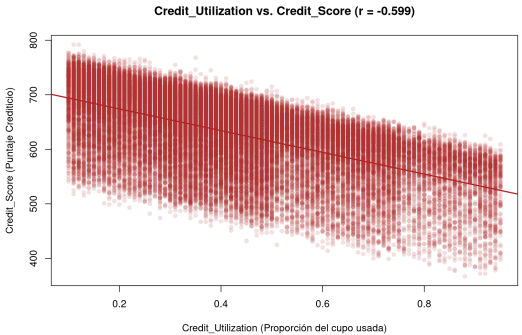
# El "punto imposible" ‖ Normal en cada variable por separado, imposible en conjunto




Un cliente con `Payment_Ratio=0.95` y `Credit_Score=460` (izq.), o con `Annual_Income=3.000.000` y `Credit_Limit=200` (der.), pasa **ambos** filtros univariados de Tukey — pero cae fuera de la nube conjunta: la normalidad marginal no garantiza la normalidad conjunta.

# Confirmando la selección ‖ Comportamiento de pago vs. uso del cupo

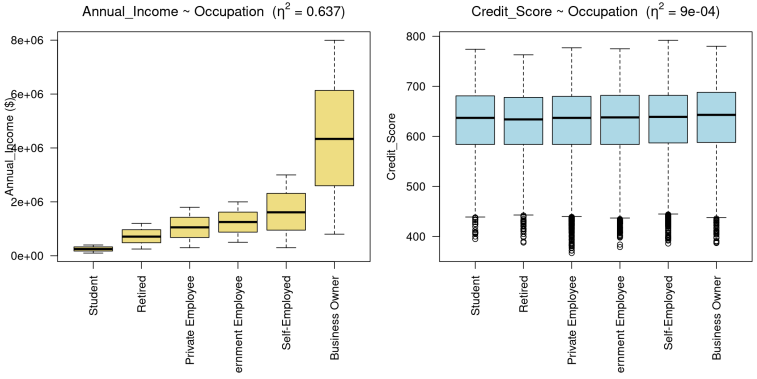



**Matriz de correlación del núcleo bivariado**

| | Income | Limit | Score |
|---|---|---|---|
| Income | 1.00 | 0.97 | 0.03 |
| Limit | 0.97 | 1.00 | 0.04 |
| Payment_Ratio | 0.00 | 0.00 | 0.77 |
| Credit_Util. | 0.00 | 0.00 | -0.60 |

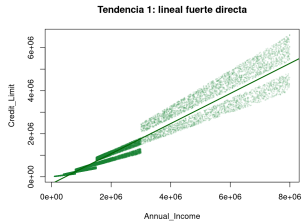
El cupo lo determina casi exclusivamente el ingreso ($r = 0.97$); el buen puntaje depende del comportamiento: pagar ($r = 0.77$) y no sobreusar el cupo ($r = -0.60$).

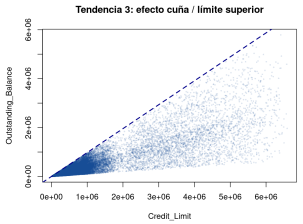
# Comparación por grupos: `Occupation` ‖ Informativa aquí, ruido en la otra

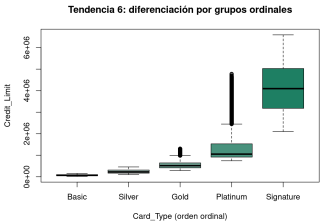



**Izquierda:** las cajas de `Annual_Income` suben en escalera sin traslape — de `Student` a `Business Owner`, razón de casi 17 a 1 entre sus medias ($\eta^2 = 0.637$). **Derecha:** las cajas de `Credit_Score` son indistinguibles entre sí ($\eta^2 = 0.0009$) — la misma categórica es informativa para una variable y ruido puro para otra.

# Patrones bivariados de la cartera ‖ Lineal directa, límite físico y grupos ordinales




**Lineal directa:** Income→Limit sube en banda angosta; usar ambas duplica la misma información.

**Efecto cuña:** nadie debe más de lo que su cupo permite — límite físico, no causa proporcional.

**Grupos ordinales:** `Card_Type` sube en el mismo orden que su jerarquía, sin inversiones.

# Por qué y cómo se estandariza ‖ $z = (x - \bar{x})/s$: mismo idioma para 26 escalas distintas

## El problema de escala

| **Annual_Income** | **Credit_Utilization** |
|---|---|
| sd = 1.407.257 | sd = 0.206 |

Las 26 numéricas difieren en desviación estándar por una razón de **6.835.059** veces entre la más dispersa y la menos dispersa. Graficarlas juntas en su escala original es imposible de leer: una sola variable domina el eje y esconde a las demás.

## La transformación

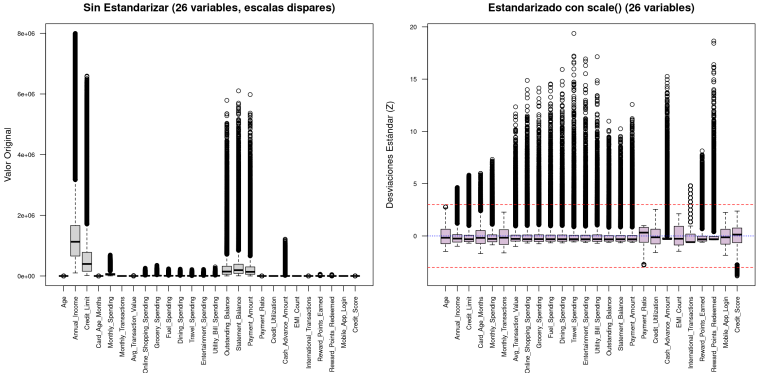
$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

Cada variable se convierte en su propio número de desviaciones estándar respecto a su media. Tras esto, **toda variable queda con media 0 y sd 1**, sin importar su unidad original.

Esto **no cambia la forma** de la distribución: solo la escala, para que todas hablen el mismo idioma y se comparen en un solo eje.

Es la misma decisión que separa un PCA sobre la matriz de covarianzas de uno sobre la matriz de correlaciones — por eso es indispensable antes de PCA y *clustering*.

# Comparación estandarizada ‖ Las 26 variables, antes y después de `scale()`




**Izquierda:** 24 de 26 cajas son una línea plana pegada al cero — `Annual_Income` y `Credit_Limit` esconden todo lo demás. **Derecha:** las 26 comparten el mismo eje y por fin se puede comparar su dispersión y colas.

# Diagnóstico de colas máximas ‖ A cuántas $\sigma$ de su media está el máximo

**Colas más largas (mayor Z máximo)**

| Variable | $Z_{max}$ |
|---|---|
| Travel_Spending | 19.37 |
| Reward_Points_Redeemed | 18.65 |
| Utility_Bill_Spending | 17.14 |
| Entertainment_Spending | 16.93 |
| Dining_Spending | 15.92 |

**Colas más cortas (acotadas, sin outliers)**

| Variable | $Z_{max}$ |
|---|---|
| Credit_Utilization | 2.54 |
| Credit_Score | 2.38 |
| Monthly_Transactions | 2.28 |
| Mobile_App_Login | 2.25 |
| EMI_Count | $\sim$2.0 |

**Travel_Spending** tiene el máximo más extremo (19.37$\sigma$ por encima de su media) — es el gasto más esporádico de todos: la mayoría viaja poco o nada, y los pocos que viajan lo hacen con montos grandes. Este ranking coincide con el mismo grupo de variables de cola larga identificadas en los histogramas univariados.

# Con cuáles variables nos quedamos ‖ Tres criterios: clasificación, redundancia, selección

**21 de 26**

variables numéricas retenidas para PCA / clustering

**Capacidad y demografía**

`Age`, `Annual_Income`, `Credit_Limit`, `Card_Age_Months`

**Gasto por categoría**

`Online_Shopping`, `Grocery`, `Fuel`, `Dining`, `Travel`, `Entertainment`, `Utility_Bill`

**Saldos y pagos**

`Statement_Balance`, `Payment_Amount`, `Avg_Transaction_Value`, `Monthly_Transactions`

**Comportamiento y riesgo**

`Cash_Advance`, `EMI_Count`, `Intl._Transactions`, `Reward_Redeemed`, `Mobile_Login`, `Credit_Score`

**Las 3 categóricas** (`Gender`, `Occupation`, `Card_Type`) no entran a un PCA clásico sobre la matriz de correlación, pero se conservan aparte para perfilar los clusters resultantes; `Card_Type` es candidata a codificarse como entero ordinal 1–5.

# Variables descartadas y por qué (5) ‖ Ninguna exclusión es por mala calidad

| Variable | Motivo de exclusión |
|---|---|
| `Monthly_Spending` | Es la suma exacta de las 7 categorías de gasto retenidas por separado: colinealidad garantizada ($r = 1$). |
| `Outstanding_Balance` | $r = 0.997$ con `Statement_Balance` — misma información económica dos veces; se retiene `Statement_Balance`. |
| `Reward_Points_Earned` | $r = 0.980$ con `Monthly_Spending`: función casi lineal del gasto, sin información propia. |
| `Payment_Ratio` | Cociente derivado de columnas ya retenidas; vuelve casi singular la matriz de covarianzas. |
| `Credit_Utilization` | Cociente derivado (Balance/Cupo); misma razón que `Payment_Ratio`. |

**Caso especial:** `Payment_Ratio` y `Credit_Utilization` se excluyen de la construcción del PCA/clusters por colinealidad, pero — precisamente por ser las variables que más predicen `Credit_Score` — se recomienda reincorporarlas después como variables **suplementarias** para interpretar los resultados, no para construirlos.

# Gracias

De la importación de los datos a la selección final de variables para PCA y *clustering*.

Oscar Manuel Contreras Gacha · Juan Pablo Sarmiento Ramírez
Steven Navarro Parrales · Juan Diego Grajales Castillo